


Проблемы индустриальных рекомендательных систем

Осиновсков Илья, 30.03.2026. AI masters.




Проблемы

- Разнообразие
- Холодный старт
- Смещения

Разнообразие

- Важный аспект качества рекомендаций, который характеризует степень различия между предлагаемыми пользователю объектами.
- Обычно противопоставляется точности рекомендаций и служит дополнительным критерием оценки эффективности рекомендаций.

Почему разнообразие важно?



A single slate of recs but
not boosted for diversity



A single slate of recs with more
diversity of topics

Fig 1: Example of diversity

Почему разнообразие важно?

- Современные рекомендательные системы, стремясь максимизировать точность предсказаний, часто создают "пузыри фильтрации", ограничивая спектр контента, с которым взаимодействует пользователь.

Почему разнообразие важно?

- Способствует открытию нового контента пользователями, расширяя их кругозор и предотвращая когнитивные искажения
- Разнообразие помогает избежать эффекта "популярности", когда популярные элементы становятся еще популярнее, а менее известные - остаются незамеченными.
- Способствует справедливому представлению различных категорий контента и создателей, что особенно актуально в музыкальных сервисах, новостных платформах и социальных сетях.

Типы разнообразия в рекомендательных системах

- Индивидуальное
- Агрегированное

Типы разнообразия в рекомендательных системах

- **Индивидуальное**
Мера разнообразия элементов, рекомендуемых конкретному пользователю. Отражает, насколько различаются между собой предложения в персональном списке рекомендаций по характеристикам, тематикам и атрибутам.
- **Агрегированное**

Типы разнообразия в рекомендательных системах

- Индивидуальное

- Агрегированное

Мера распределения рекомендаций по всей базе элементов для всех пользователей системы.

Показывает, насколько широко используется каталог объектов в рекомендациях, предотвращая концентрацию только на популярных элементах и обеспечивая видимость для элементов "длинного хвоста", что способствует более справедливому распределению внимания пользователей

Метрики индивидуального разнообразия

Intra-list diversity

- Относится к разнообразию элементов внутри одного списка рекомендаций для конкретного пользователя. Например, вместо рекомендации десяти боевиков, система может предложить фильмы разных жанров.

$$ILD(L) = \frac{2}{|L| \cdot (|L| - 1)} \sum_{i=1}^{|L|-1} \sum_{j=i+1}^{|L|} d(i, j)$$

где:

- L — список рекомендаций
- $|L|$ — размер списка
- $d(i, j)$ — функция расстояния (или несходства) между элементами i и j
- Суммы $\sum_{i=1}^{|L|-1} \sum_{j=i+1}^{|L|}$ обеспечивают учет всех уникальных пар элементов в списке
- Множитель $\frac{2}{|L| \cdot (|L| - 1)}$ нормализует сумму, чтобы получить среднее значение расстояния для всех возможных пар в списке. Общее количество таких пар равно $C_{|L|}^2 = \frac{|L| \cdot (|L| - 1)}{2}$

Временное разнообразие

- Рассматривает изменение рекомендаций со временем, предотвращая повторение одних и тех же типов контента день за днем.

Временное разнообразие

- Рассматривает изменение рекомендаций со временем, предотвращая повторение одних и тех же типов контента день за днем.
- Можно использовать меру Жаккара между списками рекомендаций за разные дни

Новизна

- На основе популярности

1. Будем рассматривать собственную информацию item-а как меру его новизны для пользователей.

$$selfInformation(i) = -\log_2 \frac{|u_i|}{N},$$

где i - объект (item), N - число пользователей в обучающей выборке, $|u_i|$ - число пользователей, взаимодействовавших с объектом i в обучающей выборке.

2. Собственная информация определяется для item-а, а значение метрики мы хотим считать для пользователя и k - количества рекомендаций. Для подсчета Surprisal пользователя усредним значения собственной информации в топ- k рекомендациях этого пользователя.

Чтобы получить значения от 0 до 1, разделим значение метрики для пользователя на максимально возможно значение метрики равное $\log_2 N$.

$$Novelty(u, k) = \frac{1}{k \log_2 N} \sum_i^k selfInformation(i)$$

3. Результат усредним по пользователям.

Новизна

- На основе истории пользователя

$$Novelty(L, H) = 1 - \frac{|L \cap H|}{|L|}$$

где:

L — список рекомендаций

H — история предыдущих взаимодействий пользователя

Неожиданность

- Неожиданность (Unexpectedness) измеряет степень отклонения рекомендаций от ожидаемых пользователем или известных ему элементов.

- Базовая формула неожиданности

$$Serendipity(L) = \frac{1}{|L|} \sum_{i \in L} rel(i) \cdot unexp(i)$$

где:

L — список рекомендаций

$rel(i)$ — релевантность элемента i для пользователя

$unexp(i)$ — неожиданность элемента i для пользователя

Метрики агрегированного разнообразия

Покрытие каталога

- Покрытие каталога (Catalog Coverage) измеряет долю всех доступных элементов, которые когда-либо рекомендуются пользователям, что особенно важно для борьбы с предвзятостью в сторону популярного контента.

Покрытие каталога

- Покрытие каталога (Catalog Coverage) измеряет долю всех доступных элементов, которые когда-либо рекомендуются пользователям, что особенно важно для борьбы с предвзятостью в сторону популярного контента.
- Индекс Джини и коэффициент энтропии Шеннона используются для оценки равномерности распределения рекомендаций между элементами каталога.

$$H = - \sum_{i \in \mathcal{I}} p(i) \log_2 p(i), \quad p(i) = \frac{|\{u \in \mathcal{U} | i \in \mathcal{R}_u\}|}{\sum_{j \in \mathcal{I}} |\{u \in \mathcal{U} | j \in \mathcal{R}_u\}|}$$

**Высокое индивидуальное разнообразие !=
высокое агрегированное разнообразие**

Компромисс между точностью и разнообразием

- Фундаментальный вызов в разработке рекомендательных систем — поиск баланса между точностью предсказаний и разнообразием рекомендаций.
Точность, традиционно измеряемая такими метриками как RMSE, Precision@k и Recall@k, отражает способность системы предсказывать предпочтения пользователя и рекомендовать релевантные элементы.

Компромисс между точностью и разнообразием

- Однако стремление к максимальной точности часто приводит к однородным рекомендациям, сконцентрированным вокруг явных интересов пользователя.

Компромисс между точностью и разнообразием

- Бюджет разнообразия — количество разнообразия, которое можно ввести без значительной потери точности.
- При этом оптимальная точка этого компромисса индивидуальна для каждого пользователя и зависит от контекста использования системы. Например, в новостных рекомендациях пользователи обычно ценят разнообразие выше, чем в специализированных технических рекомендациях.
- Современные подходы направлены на персонализацию этого компромисса, где система адаптивно определяет оптимальный баланс для каждого пользователя на основе его поведения и явных предпочтений.

Алгоритмические подходы к увеличению разнообразия

Ручные правила

- Не ставить объекты одного кластера ближе чем k позиций

Квотирование

- Распределить N мест среди всех кластеров объектов
- Кластеры
 - Обучаемые
 - Категории/жанры/etc
- Выбор размера квоты для кластеры
 - Одна квота на все кластеры
 - Распределение интересов пользователя по кластерам

Maximum marginal Relevance

Algorithm 1: Greedy Algorithm for Diversity Enhancement

Input: Recommendation number top K , coefficient λ

```
1 return Recommendation list  $\mathcal{R}_u$ 
2 Init recommendation list  $\mathcal{R}_u = \{\}$ 
3 for  $|\mathcal{R}_u| < K$  do
4    $i^* = \operatorname{argmax}_{i \in I \setminus \mathcal{R}_u} s(\mathcal{R}_u \cup \{i\}, \lambda)$ 
5    $\mathcal{R}_u = \mathcal{R}_u \cup \{i^*\}$ 
6 return  $\mathcal{R}_u$ ;
```

$$s(\mathcal{R}_u, \lambda) = \frac{1 - \lambda}{|\mathcal{R}_u|} \sum_{i \in \mathcal{R}_u} f_{\text{rec}}(i) + \lambda f_{\text{div}}(\mathcal{R}_u)$$

Determinantal Point Process

- Математическая модель, которая изначально использовалась в квантовой физике для описания отталкивания заряженных частиц.

В контексте рекомендательных систем она помогает моделировать "отталкивание" между похожими элементами.

Determinantal Point Process

- Ключевая особенность DPP в том, что вероятность выбора подмножества элементов пропорциональна определителю матрицы, элементы которой отражают как качество отдельных элементов, так и их сходство между собой.

Determinantal Point Process

- Матрица ядра (L-matrix) - центральный элемент DPP. Для каждой пары элементов i и j матрица содержит значение $L(i,j)$, которое отражает их сходство. Диагональные элементы $L(i,i)$ представляют релевантность элемента i .
- Хотим набрать такую матрицу из N элементов, определитель которой будет максимален
- Точное решение NP-сложное, поэтому будем пользоваться жадным

Determinantal Point Process

- Точное решение NP-сложное, поэтому будем пользоваться жадным
- Даже в жадном нам надо считать определитель матрицы от N элементов, что имеет кубическую сложность относительно N
- В статье предлагается использовать разложение Холецкого для ускорения вычислений

Статья https://lsrs2017.wordpress.com/wp-content/uploads/2017/08/lsrs_2017_lamingchen.pdf

MULTISLOT RERANKER: A GENERIC MODEL-BASED RE-RANKING FRAMEWORK IN RECOMMENDATION SYSTEMS

Algorithm 1 Sequential Greedy Algorithm

Require: $i \geq 0$ and $i < N$ ▷ i is slot or position index, N is total number items.
Select item with top SPR score and place it to slot 0
 $i \leftarrow 1$ ▷ The slot 0 does not have previous slot
 $C \leftarrow \{0 \dots K - 1\}$ ▷ Initialize top K candidate set by second pass ranking scores
while $i < N$ **do**
 $reranking_score_max \leftarrow -\infty$
 $k \leftarrow 0$ ▷ Select item k from Candidates
 for $a \in C$ **do**
 Extract features from item a
 Extract interaction features between item a and the previous slot $i - 1$
 Calculate score by equation 1
 if $score > reranking_score_max$ **then**
 $reranking_score_max \leftarrow score$
 $k \leftarrow a$ ▷ Pick the item with largest re-ranking score, i.e., greedy
 end if
 end for
 Remove item k from Candidate set C and place it to slot i
 Pick the next top item in remaining list and add it to top K Candidate set C
 $i \leftarrow i + 1$
end while

- Стаття <https://arxiv.org/pdf/2401.06293>

MULTISLOT RERANKER: A GENERIC MODEL-BASED RE-RANKING FRAMEWORK IN RECOMMENDATION SYSTEMS

Table 1: A List of Features for Sequential Greedy Algorithm

Feature Category	Features
Second Pass Ranking Scores	p(Click) Contribution responses such as p(Like), p(Comment), p(Share), p(Skip) p(Contributions) whose label is positive if any of Like, Comment, Share, Skip is positive.
Current Slot's Features	Slot index i Embeddings of item at slot i Type of item at slot i such as Video, Image, Job, Company, Article, etc.
Interaction Features	Type of items in previous slots Count of each type of items in previous slots Cross feature with item type among slot i and previous slots Embeddings dot product of items among current slot i and previous slots Whether items at current slot i and previous slots are created by the same user

- Стаття <https://arxiv.org/pdf/2401.06293>

Exploration-exploitation trade off

Exploration-exploitation trade off

- **Exploitation:** рекомендовать то, что с высокой вероятностью понравится

Exploration-exploitation trade off

- **Exploitation:** рекомендовать то, что с высокой вероятностью понравится
- **Exploration:** исследовать новые возможности для получения информации

Exploration-exploitation trade off

- **Exploitation:** рекомендовать то, что с высокой вероятностью понравится
- **Exploration:** исследовать новые возможности для получения информации
- **Дилемма:**
 - слишком много exploitation ведет к «фильтр-пузырям»

Exploration-exploitation trade off

- **Exploitation:** рекомендовать то, что с высокой вероятностью понравится
- **Exploration:** исследовать новые возможности для получения информации
- **Дилемма:**
 - слишком много exploitation ведет к «фильтр-пузырям»
 - слишком много exploration: ухудшение пользовательского опыта

Exploration-exploitation trade off

- **Exploitation:** рекомендовать то, что с высокой вероятностью понравится
- **Exploration:** исследовать новые возможности для получения информации
- **Дилемма:**
 - слишком много exploitation ведет к «фильтр-пузырям»
 - слишком много exploration: ухудшение пользовательского опыта
- **Ключевой вопрос:** как найти оптимальный баланс?

Фильтр-пузыри и их последствия

- **Определение:** изоляция контента из-за персонализированных алгоритмов
- **Проблемы:**
 - Ограничение разнообразия контента
 - Усиление существующих убеждений
 - Идеологическая/информационная поляризация
- **Решения:**
 - Намеренная диверсификация
 - Serendipity-ориентированные алгоритмы
 - Пользовательский контроль над параметрами рекомендаций

Алгоритмы для exploration-exploitation

Алгоритмы для exploration-exploitation

ϵ -greedy

- Основной принцип
 - С вероятностью $1 - \epsilon$: выбираем лучшие элементы на основе текущей модели (использование)
 - С вероятностью ϵ : выбираем случайные элементы (исследование)

Алгоритмы для exploration-exploitation

ϵ -greedy

- **Основной принцип**

- С вероятностью $1 - \epsilon$: выбираем лучшие элементы на основе текущей модели (использование)
- С вероятностью ϵ : выбираем случайные элементы (исследование)

- **Математическая формулировка**

- Вероятность рекомендации элемента i пользователю u :

$$P(i | u) = \begin{cases} 1 - \epsilon + \frac{\epsilon}{|I|}, & \text{если } i = \arg \max_j \hat{r}_{uj} \\ \frac{\epsilon}{|I|}, & \text{иначе} \end{cases}$$

где $\hat{r}_{uj}$ - предсказанная релевантность элемента i для пользователя u

Алгоритмы для exploration-exploitation

Upper Confidence Bound (UCB):

- **Ключевая идея:** Вместо случайного исследования, как в ϵ -greedy, UCB систематически выбирает элементы с наибольшим потенциалом, балансируя между:
 - Оценкой ожидаемой награды (использование)
 - Уровнем неопределенности этой оценки (исследование)
- **Математическая формулировка:**

Для каждого элемента i и пользователя u вычисляется UCB-оценка: $UCB_{ui} = \hat{r}_{ui} + c \cdot \sqrt{\frac{2 \ln n}{n_i}}$

где:

- $\hat{r}_{ui}$ - текущая оценка релевантности элемента i для пользователя u
- n - общее количество взаимодействий
- n_i - количество взаимодействий с элементом i
- c - параметр, контролирующий уровень исследования

Алгоритмы для exploration-exploitation

- Есть еще:
 - Семплирования Томпсона
 - Контекстные многорукие бандиты

Многоуровневая система


retrieval

filtering

ranking

re-ranking

Многоуровневая система



Проблема холодного старта

Проблема холодного старта

- **Определение:** Невозможность формирования качественных рекомендаций из-за отсутствия данных

Проблема холодного старта

- **Определение:** Невозможность формирования качественных рекомендаций из-за отсутствия данных
- **Холодный старт пользователя:** новый пользователь без истории взаимодействий

Проблема холодного старта

- **Определение:** Невозможность формирования качественных рекомендаций из-за отсутствия данных
- **Холодный старт пользователя:** новый пользователь без истории взаимодействий
- **Холодный старт контента:** новый элемент, с которым еще никто не взаимодействовал

Проблема холодного старта




- **Определение:** Невозможность формирования качественных рекомендаций из-за отсутствия данных
- **Холодный старт пользователя:** новый пользователь без истории взаимодействий
- **Холодный старт контента:** новый элемент, с которым еще никто не взаимодействовал
- **Последствия:** низкое качество рекомендаций, снижение вовлеченности

Холодный старт пользователя

Холодный старт пользователя

Явный сбор предпочтений

- онбординг
- КВИЗЫ
- начальные оценки



Холодный старт пользователя

Использование демографии

- пол
- возраст
- локация
- образование
- ...

Холодный старт пользователя

Использование демографии

- **Примеры из индустрии:**
 - **Amazon:** Адаптирует первоначальные рекомендации в зависимости от местоположения пользователя, предлагая сезонные товары, региональные бестселлеры и продукты, популярные в данном регионе.
 - **LinkedIn:** Анализирует указанную должность, компанию и образование для формирования первых рекомендаций по людям, группам и контенту.
 - **Disney+:** Предлагает контент в зависимости от возрастной группы пользователя, выделяя мультфильмы для детей и более серьезный контент для взрослой аудитории.
 - **The New York Times:** Подбирает первоначальные статьи с учетом географического положения читателя, например, больше местных новостей для американской аудитории.

Холодный старт пользователя

Сессионные рекомендации

- Сессионные рекомендации фокусируются на текущем взаимодействии пользователя с системой, а не на долгосрочной истории. Система анализирует действия пользователя в реальном времени и динамически адаптирует рекомендации.

Холодный старт пользователя

Сессионные рекомендации

- **Примеры из индустрии:**
 - **TikTok:** Использует сложные алгоритмы, которые отслеживают время просмотра каждого видео, взаимодействие с ним (лайки, комментарии, сохранения) и мгновенно корректируют контент в ленте. Достаточно 10-15 минут использования для создания высокорелевантных рекомендаций.
 - **Pinterest:** Адаптирует показ пинов на основе того, какие изображения пользователь просматривает и сохраняет в рамках одной сессии, быстро переходя к релевантному контенту.
 - **Booking.com:** Изменяет рекомендуемые отели в режиме реального времени в зависимости от параметров, которые пользователь просматривает (ценовой диапазон, местоположение, рейтинг).
 - **Steam:** Анализирует, какие игры просматривает пользователь, формируя раздел "Рекомендуемое для вас" динамически в рамках одного сеанса.

Холодный старт пользователя

Сессионные рекомендации

- Когда пользователь взаимодействует хотя бы с одним элементом, мы можем применить подход item2item:
 - Рекомендуем товары, которые часто просматриваются вместе с текущим

Холодный старт пользователя

Сессионные рекомендации

- Когда пользователь взаимодействует хотя бы с несколькими элементами, мы можем перейти к более сложным подходам:
 - ALS
 - Нейросети

Холодный старт пользователя

Сессионные рекомендации - ALS

- Вместо полного переобучения модели мы можем адаптировать существующую модель для нового пользователя:
 - **Предварительный этап:** обучаем ALS модель на существующих данных
 - Получаем матрицу латентных факторов предметов P
 - Получаем матрицу латентных факторов пользователей Q
 - **Этап реального времени:** фиксируем факторы предметов P и обновляем только факторы нового пользователя

Холодный старт пользователя

Сессионные рекомендации - ALS

- **Этап реального времени:** фиксируем факторы предметов P и обновляем только факторы нового пользователя
 - Для нового пользователя u с имеющимися рейтингами r_{ui} для предметов i :

Оптимизируем только вектор пользователя $q_u = \arg \min_{q_u} \sum_{i \in I_u} (r_{ui} - p_i^T q_u)^2 + \lambda ||q_u||^2$

где:

- I_u — множество предметов, с которыми взаимодействовал пользователь u
 - p_i — вектор латентных факторов предмета i (фиксированный)
 - λ — параметр регуляризации
- Аналитическое решение: $q_u = (P_{I_u}^T P_{I_u} + \lambda I)^{-1} P_{I_u}^T r_u$

где:

 - P_{I_u} — матрица латентных факторов предметов, с которыми взаимодействовал u
 - r_u — вектор рейтингов пользователя u

Холодный старт пользователя

Сессионные рекомендации

- Использовать модели на последовательностях действий:
 - Bert4Rec
 - SASRec
 - ...
- Смотрите 8 лекцию

Холодный старт пользователя

Социальная авторизация

- Позволяет новым пользователям "импортировать" предпочтения и связи из существующих социальных сетей, создавая первичный набор предпочтений.
- **Примеры из индустрии:**
 - **Goodreads:** При авторизации через Facebook сервис анализирует страницы книг, авторов и издательств, которые пользователь лайкнул, а также получает доступ к предпочтениям друзей, формируя начальные рекомендации по чтению.
 - **Spotify:** Интегрируется с Facebook и другими социальными сетями, что позволяет сразу показывать музыку, популярную среди друзей пользователя, а также автоматически формировать плейлисты на основе общих предпочтений.
 - **Strava:** При подключении через социальные сети сразу предлагает подписаться на друзей, которые уже используют платформу, и показывает популярные маршруты среди этой группы.

Холодный старт пользователя

Активное обучение

- Стратегически выбираем элементы для оценки пользователем, максимизируя информационную ценность каждого взаимодействия.
- **Цель** — быстрое и эффективное формирование точного профиля предпочтений при минимальном количестве запросов.
- **Примеры из индустрии:**
 - **MovieLens:** Вместо случайного набора популярных фильмов система выбирает те, которые помогут точнее определить вкусы — например, фильмы, разделяющие пользователей на четкие группы по предпочтениям.
 - **StitchFix:** Применяет адаптивные опросники, где каждый следующий вопрос о стиле одежды зависит от предыдущих ответов, что позволяет быстро сузить диапазон предпочтений пользователя.
 - **Pandora:** Использует специально подобранную последовательность треков для оценки, алгоритмически выбирая композиции, покрывающие различные музыкальные характеристики.
 - **Hinge:** Датинговое приложение просит оценить специально подобранные профили, чтобы определить предпочтения в партнерах по ключевым параметрам.

Холодный старт пользователя

- **Явный сбор предпочтений:** онбординг, квизы, начальные оценки
- **Использование демографии:** рекомендации на основе возраста, локации, образования
- **Сессионные рекомендации:** использование текущих действий пользователя
- **Социальная авторизация:** заимствование данных из социальных профилей
- **Активное обучение:** стратегический выбор элементов для оценки пользователем

Холодный старт контента

Холодный старт контента

Контентная фильтрация

- Опирается на структурированные и неструктурированные метаданные, позволяя рекомендовать новые элементы без истории взаимодействий, на основе их характеристик и соответствия профилям пользователей.

Холодный старт контента

Контентная фильтрация

- Опирается на структурированные и неструктурированные метаданные, позволяя рекомендовать новые элементы без истории взаимодействий, на основе их характеристик и соответствия профилям пользователей.
- **Примеры из индустрии:**
 - **Netflix:** Использует более 3000 микро-жанров и тегов для каждого фильма или сериала, включая такие детальные характеристики как "Криминальные триллеры с сильной женской ролью", что позволяет рекомендовать новые релизы, соответствующие профилям пользователей.
 - **Spotify:** Классифицирует новые треки по 400+ музыкальным характеристикам, включая темп, инструментовку, настроение и энергичность, что позволяет включать новинки в плейлисты без предварительных прослушиваний.
 - **Steam:** Анализирует метаданные новых игр (жанр, графический стиль, однопользовательский/многопользовательский режим) для соотнесения с предпочтениями геймеров.

Холодный старт контента

Анализ текста и изображений

- Автоматическое извлечение признаков использует методы компьютерного зрения, обработки естественного языка и аудиоанализа для создания векторных представлений нового контента без необходимости ручной разметки метаданных.

Холодный старт контента

Анализ текста и изображений

- Автоматическое извлечение признаков использует методы компьютерного зрения, обработки естественного языка и аудиоанализа для создания векторных представлений нового контента без необходимости ручной разметки метаданных.
- **Примеры из индустрии:**
 - **YouTube:** Автоматически анализирует содержание видео, извлекая информацию о визуальных сценах, транскрибирует речь и распознает объекты, что позволяет предлагать новый контент до накопления достаточного количества просмотров.
 - **Pinterest:** Использует системы компьютерного зрения для автоматического понимания содержания новых изображений, определяя объекты, цветовые схемы, стили и композицию для точной категоризации и рекомендации.
 - **Medium:** Применяет NLP-модели для анализа новых статей, автоматически определяя тематику, сложность текста, эмоциональный тон и ключевые концепции.

Холодный старт контента

Стратегии первоначального продвижения

- Временное повышение видимости нового контента для преодоления "барьера первого взаимодействия" путем сознательного увеличения его показов для формирования начальной обратной связи и данных о взаимодействиях.

Холодный старт контента

Стратегии первоначального продвижения

- Временное повышение видимости нового контента для преодоления "барьера первого взаимодействия" путем сознательного увеличения его показов для формирования начальной обратной связи и данных о взаимодействиях.
- **Механизмы реализации:**
 - **Управляемая экспозиция:** представление нового контента определенному проценту пользователей независимо от их предыдущих предпочтений
 - **Разделение интерфейса:** создание специальных разделов "Новинки" или "Попробуйте что-то новое»
 - **Временное повышение рейтинга:** искусственное увеличение релевантности нового контента в алгоритмах ранжирования

Холодный старт контента

Стратегии первоначального продвижения

- **Примеры из индустрии:**
 - **TikTok:** Использует систему "контролируемого тестирования", когда новое видео показывается небольшой выборке пользователей (~300-500 человек). Алгоритм оценивает коэффициент завершения просмотра, время задержки, количество взаимодействий, и если метрики положительные, постепенно увеличивает охват.
 - **Amazon Prime Video:** Выделяет раздел "Новые релизы" с особым дизайном и стратегически размещает его на домашнем экране всех пользователей, гарантируя видимость новому контенту.
 - **Apple Podcasts:** Использует кураторские списки "New & Noteworthy" для продвижения новых подкастов, давая им шанс получить первоначальные прослушивания и отзывы.
 - **Новостные агрегаторы:** Временно повышает видимость новостных статей по новым событиям для сбора начальных данных о взаимодействии.

Холодный старт контента

Трансферное обучение

- Основано на принципе переноса знаний о взаимодействиях пользователей с существующими элементами на похожие новые элементы, что позволяет "заимствовать" начальные паттерны потребления.

Холодный старт контента

Трансферное обучение

- Основано на принципе переноса знаний о взаимодействиях пользователей с существующими элементами на похожие новые элементы, что позволяет "заимствовать" начальные паттерны потребления.
- **Примеры из индустрии:**
 - **Amazon Books:** Когда новая книга автора появляется в каталоге, система автоматически применяет данные о взаимодействиях пользователей с предыдущими книгами этого автора для начального позиционирования.
 - **YouTube Music:** Использует информацию о прослушивании предыдущих треков артиста для создания "прогнозируемой аудитории" для нового релиза, целенаправленно предлагая его фанатам исполнителя.
 - **HBO Max:** Применяет данные о просмотрах предыдущих сезонов или похожих шоу для формирования первоначальной аудитории для новых сериалов.
 - **Steam:** Анализирует поведение пользователей с играми одного разработчика, жанра или серии для построения начальных моделей рекомендаций для новых релизов.

Холодный старт контента

- **Контентная фильтрация:** использование метаданных и характеристик
- **Анализ текста и изображений:** автоматическое извлечение признаков
- **Стратегии первоначального продвижения:** временное повышение ВИДИМОСТИ
- **Трансферное обучение:** использование данных похожего контента

Смещения в рекомендательных системах

Смещения в рекомендательных системах

- Что такое смещения (biases):
 - Систематические отклонения в рекомендациях, которые приводят к непропорциональному представлению определенных групп, идей или продуктов
 - Несоответствие между целевой функцией рекомендательной системы и реальными интересами пользователей

Смещения в рекомендательных системах

- **Popularity Bias:** предпочтение популярных элементов

Смещения в рекомендательных системах

- **Popularity Bias:** предпочтение популярных элементов
- **Position Bias:** предвзятость к позиции элемента в интерфейсе

Смещения в рекомендательных системах

- **Popularity Bias:** предпочтение популярных элементов
- **Position Bias:** предвзятость к позиции элемента в интерфейсе
- **Selection Bias:** неравномерное представление данных о взаимодействиях

Смещения в рекомендательных системах

- **Popularity Bias:** предпочтение популярных элементов
- **Position Bias:** предвзятость к позиции элемента в интерфейсе
- **Selection Bias:** неравномерное представление данных о взаимодействиях
- **Конформное смещение:** влияние социального одобрения на оценки

Смещения в рекомендательных системах

- **Popularity Bias:** предпочтение популярных элементов
- **Position Bias:** предвзятость к позиции элемента в интерфейсе
- **Selection Bias:** неравномерное представление данных о взаимодействиях
- **Конформное смещение:** влияние социального одобрения на оценки
- **Проблема:** искажение данных, снижение разнообразия, информационные пузыри

Popularity bias

- **Пример:** В музыкальном стриминге хиты получают непропорционально больше рекомендаций, чем треки нишевых артистов, даже если последние могут больше соответствовать вкусам конкретного пользователя.
- **Методы решения:**
 - Регуляризация на основе популярности
 - Переранжирование рекомендаций для увеличения разнообразия
 - Явное введение квот для менее популярного контента

Position bias

- **Пример:** Первый результат поиска получает намного больше кликов, даже если второй или третий результаты более релевантны запросу пользователя.
- **Методы решения:**
 - Рандомизация позиций для сбора несмещенных данных
 - Модели пропускания кликов (click propensity models)
 - Inverse propensity scoring для коррекции смещений при обучении

Position bias

Рандомизация позиций для сбора несмещенных данных

- **Полная рандомизация:**
Полное перемешивание результатов для некоторой доли пользователей или запросов.
 - Преимущества:
 - Полное устранение позиционного смещения
 - Простота реализации
 - Недостатки:
 - Значительное ухудшение пользовательского опыта
- **Частичная рандомизация:**
Рандомизация в пределах групп близких по релевантности результатов.

Position bias

Модели пропускания кликов (Click Propensity Models)



- **Определение:** Модели пропускания кликов оценивают вероятность того, что пользователь заметит и рассмотрит элемент в определенной позиции, независимо от его релевантности.
- Вероятностная модель клика:
$$P(\textit{click} \mid d, q, r) = P(\textit{click} \mid d, q) \cdot P(\textit{view} \mid r)$$

где:
 - d — документ или элемент
 - q — запрос пользователя
 - r — позиция (ранг) в выдаче
 - $P(\textit{view} \mid r)$ — вероятность просмотра позиции r (propensity)

Position bias

Обучение с учетом позиции

- **Обучение:**
 - Проставляем позицию в признаки
- **Применение:**
 - Заменяем позицию константным значением



Selection bias

- **Пример:** В системе рекомендации фильмов пользователи обычно смотрят и оценивают фильмы, которые им интересны, оставляя неясным отношение к фильмам, которые они не выбрали.
- **Методы решения:**
 - Негативный сэмплинг
 - Техники заполнения пропущенных данных

Selection bias

Негативный семплинг

- Равномерный
- Популярностно-взвешенный
- На основе сходства
- ...

Вопросы